


# 1 Analiza zależności między

Analizujemy zależność między ceną, a objętością. Przyjrzyjmy się zależności naszych danych na wykresie.



Rysunek 1: Wykres cena-objętość

Z wykresu możemy zauważyć silną zależność między naszymi danymi. Z powodu rozłożenia naszych danych zależność ta może być liniowa. W celu określenia tej zależności obliczymy współczynnik korelacji pearsona

$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \approx 0.93,$$

gdzie  $x_i$ ,  $y_i$  to  $i$ -te obserwacje odpowiednio objętości oraz ceny,  $\bar{x}$  oznacza średnią z  $x$ , a  $n$  to rozmiar próby, oznaczeniami tymi będziemy posługiwali się w całym raporcie. Wartość ta jest blisko wartości 1, zatem nasze dane są silnie skorelowane dodatnie oraz liniowo. Dlatego model, którym będziemy opisywać dane będzie miał postać

$$(1) \quad Y_i = \beta_0 + \beta_1 x_i + \xi_i,$$

gdzie  $\xi_i$  jest losowym błędem pomiarowym.  $Y_i$  jest zmienną losową, której realizacją jest zaobserwowana wartość  $y_i$ . Zgodnie z treścią polecenia zakładamy, że wszystkie zminne losowe  $\xi_i$  są idd. oraz mają rozkład normalny ze średnią 0. Naszym zadaniem będzie estymować wartość  $\hat{y}_i$  poprzez estymowanie realizacji zmiennych losowych  $\hat{\beta}_0$  oraz  $\hat{\beta}_1$ .

## 1.1 Estymacja punktowa

By stworzyć estymator ceny  $\hat{y}$  skorzystamy z metody najmniejszych kwadratów. Do estymacji parametrów  $\beta_0$  oraz  $\beta_1$ , występujące we wzorze (1), wykorzystamy losowo wybrane 80% naszych danych. Pozostałe

20% posłuży nam w celu sprawdzenie poprawności modelu. Estymowane parametry, w danej realizacji  $Y$ , mają wartość

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \approx 39.255 \quad \text{oraz} \quad \hat{\beta}_0 = \bar{y} - \beta_1 \bar{x} \approx -1564.73.$$

Estymowana wartość ceny  $\hat{y}$  w modelu (1) będzie miała postać

$$\hat{y}_i = 39.255 \cdot x_i - 1564.73.$$

## 1.2 Estymacja przedziałowa

W tym przypadku będziemy szukać przedziału do w którym będzie należał nasz  $Y_i$  z dużym prawdopodobieństwem. Będziemy chcieli by prawdopodobieństwo to wynosiło  $1 - \alpha$ . Znany jest fakt, że w modelu (1) zmienna  $\hat{Y}_i$  ma poniższe parametry

$$\mathbb{E}\hat{Y}_i = \beta_0 + \beta_1 x_i \quad \text{oraz} \quad \text{Var}\hat{Y}_i = \text{Var}(\xi_1) \left( \frac{1}{n} + \frac{(x_0 - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right).$$

Jeśli  $\text{Var}(\xi_1)$  nie jest znana w jej miejsce wstawiamy jej estymator

$$s^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

otrzymując estymator  $\text{Var}\hat{Y}_i$  i w tym przypadku zmienna losowa

$$\frac{\hat{Y}_i - \mathbb{E}\hat{Y}_i}{s^2 \left( \frac{1}{n} + \frac{(x_0 - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)}$$

ma rozkład t-studenta z  $n - 2$  stopniami swobody. Niech  $z_{\alpha/2}$  będzie  $1 - \alpha/2$  kwantylem z tego rozkładu. Wtedy możemy napisać, że

$$\mathbb{P} \left( \hat{Y}_0 - z_{\alpha/2} s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \leq Y_0 \leq \hat{Y}_0 + z_{\alpha/2} s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}} \right) = 1 - \alpha$$